

Impacto de Ferramentas de Inteligência Artificial em Repositórios GitHub: Uma Análise Empírica

Andre Lazarini e João Pedro Guimarães
Laboratório de Experimentação em Engenharia de Software

Resumo

Este trabalho apresenta uma análise empírica de 105 repositórios Python públicos do GitHub classificados por nível de evidência de uso de IA. Para cada repositório, comparamos métricas de *issues*, retrabalho corretivo e verbosidade de *commits* nos períodos anterior e posterior ao primeiro sinal de adoção de IA. Os resultados indicam: **(RQ1)** redução na taxa de *issues* e no tempo de resolução — contrário à hipótese alternativa; **(RQ2)** aumento modesto em *fixes* e *reverts* — em linha com a hipótese alternativa; **(RQ3)** *commits* maiores pós-IA, mas sem melhora no Maintainability Index — suporte parcial.

1. Introdução

Ferramentas de IA generativa — GitHub Copilot, Claude, ChatGPT — integraram-se ao fluxo de desenvolvimento de inúmeros projetos de código aberto. Estudos prévios investigaram a qualidade do código gerado por IA [1] e a produtividade de desenvolvedores [2], mas há lacuna em análises empíricas de larga escala que comparem métricas *antes* e *depois* da introdução de sinais de IA nos repositórios.

Este trabalho aborda três questões de pesquisa:

- **RQ1:** O uso de IA impacta a taxa de abertura de *issues* e o tempo médio de resolução em projetos de software?
- **RQ2:** *Commits* assistidos por IA exigem mais retrabalho corretivo?
- **RQ3:** *Commits* assistidos por IA são mais verbosos (maiores)?

2. Trabalhos Relacionados

Dakhel et al. [1] identificaram limitações do Copilot em lógica complexa. Ziegler et al. [2] mediram a aceitação de sugestões por profissionais. Nguyen e Nadi [3] avaliaram correteude funcional de código gerado por IA.

Diferentemente desses trabalhos, nossa aborda-

gem é *observacional* e baseada em mineração de repositórios reais, comparando métricas temporais antes e depois da introdução de sinais de IA, sem experimentos controlados.

3. Metodologia

3.1. Coleta e Seleção

Foram selecionados 105 repositórios Python públicos do GitHub com pelo menos 1.000 estrelas e ao menos um sinal detectado de uso de IA. A coleta foi feita via API do GitHub e análise estática de código para o Maintainability Index (MI).

3.2. Sinais de IA e Agrupamento

Quatro tipos de evidência foram investigados: (1) co-autoria em *commits*; (2) menção ao Claude; (3) menção ao Copilot; (4) arquivo de configuração de IA. O *AI Score* = total de evidências encontradas. Grupos: **Baixo** (2–3), **Médio** (4–6), **Alto** (≥ 7).

3.3. Métricas por Questão de Pesquisa

- **RQ1 — Issues:** M1 = taxa de *issues*/mês; M2 = tempo médio de vida das *issues* (horas).
- **RQ2 — Retrabalho:** M1 = proporção de *commits* corretivos (*fixes*); M2 = taxa de *commits* de revert.
- **RQ3 — Verbosidade:** M1 = linhas alteradas por *commit*; M2 = Maintainability Index

Tabela 1: Caracterização geral.

Atributo	Valor
Repositórios	105
Mediana de estrelas	17.169
Mediana de idade	9,3 anos
Mediana AI Score	3

Tabela 2: Grupos de adoção de IA.

Grupo	n	Med.	Med. Idade	Med. Score
Baixo (2-3)	55	14.662	9,50 a	3,0
Médio (4-6)	32	18.905	9,00 a	6,0
Alto (≥ 7)	18	30.102	9,05 a	8,5

(MI) [4].

3.4. Hipóteses

Para cada RQ definimos hipótese nula (H0) e alternativa (H1):

RQ1 — H0: sem diferença em taxa de *issues* nem em tempo de resolução pré/pós IA.

RQ1 — H1: IA → maior taxa de *issues* e maior tempo de resolução.

RQ2 — H0: proporção de *fixes* e *reverts* iguais com e sem IA.

RQ2 — H1: IA → maior proporção de *commits* corretivos e mais *reverts*.

RQ3 — H0: sem diferença no tamanho de *commits* nem no MI.

RQ3 — H1: IA → *commits* maiores (mais linhas) e maior complexidade.

3.5. Análise

Para cada repositório, identificamos o primeiro sinal de IA (marco temporal) e calculamos as métricas nos períodos anterior e posterior. Adotamos a **mediana** como medida principal para reduzir o efeito de *outliers*.

4. Caracterização do Dataset

A Tabela 1 resume a amostra e a Tabela 2 detalha os grupos de adoção.

Distribuição por grupo de adoção de IA




Figura 1: Repositórios por grupo.

Tabela 3: RQ1 — medianas antes e depois.

Métrica	Antes	Depois	Δ
Taxa issues/mês	66,50	18,83	-71,7%
Tempo resolução (h)	9.898,01	5.645,14	-42,9%

5. Resultados

5.1. RQ1 — Taxa de Issues e Tempo de Resolução

Veredicto — RQ1: H1 **rejeitada**. Ambas as métricas diminuem pós-IA (taxa -71,7%; tempo -42,9%), contrariando a hipótese de que a IA aumentaria o fluxo de *issues*.

5.2. RQ2 — Retrabalho Corretivo

Veredicto — RQ2: H1 **parcialmente suportada**. Tanto *fixes* (+12,3%) quanto *reverts* (+12,7%) aumentam após a adoção de IA, em linha com a hipótese alternativa.

5.3. RQ3 — Verbosidade dos Commits

Veredicto — RQ3: H1 **parcialmente suportada**. Linhas por *commit* aumentam +12,2% (suporta H1 para tamanho), mas o MI cai ligeiramente (não suporta H1 para complexidade — código não fica mais simples).

6. Discussão

RQ1 — achado contraintuitivo. A hipótese alternativa previa mais *issues* e mais tempo de resolução após IA. Os dados mostram o oposto. Possíveis explicações: (i) a IA aumenta eficiência de triagem e resolução; (ii) o código gerado por IA apresenta menos defeitos observáveis;




Figura 2: RQ1 — M1: taxa de issues/mês antes e depois.




Figura 3: RQ1 — M2: tempo médio de resolução (horas) antes e depois.

(iii) o período pós-sinal é naturalmente mais curto, acumulando menos eventos; (iv) projetos mais maduros tendem a ter atividade decrescente independentemente da IA.

RQ2 — retrabalho leve, mas consistente. Ambas as métricas sobem de forma modesta (12%). O aumento de *fixes* e *reverts* sugere que código assistido por IA pode exigir ajustes posteriores, mas o efeito não é dramático.

RQ3 — commits maiores, sem ganho de qualidade estrutural. O aumento de linhas por *commit* pode refletir que a IA gera blocos de código maiores por interação. A queda no MI, embora pequena (3%), indica que a qualidade estrutural não melhora com a IA — o código gerado pode ser ligeiramente mais difícil de manter.

Tabela 4: RQ2 — medianas antes e depois.

Métrica	Antes	Depois	Δ
% Fixes	32,12	36,07	+12,3%
% Reverts	1,10	1,24	+12,7%

RQ2 — M1: Proporção de commits corretivos




Figura 4: RQ2 — M1: percentual de *commits* de correção antes e depois.

7. Ameaças à Validade

Interna: estudo observacional sem grupo de controle; causalidade não pode ser inferida. Variáveis de confusão (maturidade, mudança de equipe) não controladas.

Construto: AI Score mede evidência, não intensidade de uso. MI é sensível à linguagem e às ferramentas de análise.

Externa: amostra restrita a Python com ≥ 1.000 estrelas; pode não generalizar para projetos menores ou outras linguagens.

Conclusão: mediana mitiga *outliers*, mas repositórios com comportamento atípico ainda podem influenciar os resultados.

8. Conclusão


Este trabalho analisou empiricamente 105 repositórios Python quanto ao impacto de ferramentas de IA. Os resultados são:

- **RQ1:** taxa de *issues* e tempo de resolução **diminuem** pós-IA — H1 rejeitada.

Tabela 5: RQ3 — medianas antes e depois.

Métrica	Antes	Depois	Δ
Linhas/commit	193,79	217,49	+12,2%
MI médio (méd.)	63,43	60,90	-2,53
MI (mediana)	60,29	58,50	-1,80

RQ3 — M1: Tamanho médio do commit

Figura 5: RQ3 — M1: linhas alteradas por *commit* antes e depois.

- **RQ2: *fixes* e *reverts* aumentam moderadamente** — H1 parcialmente suportada.
- **RQ3: *commits* ficam maiores, mas MI cai levemente** — H1 parcialmente suportada.

Trabalhos futuros devem incluir grupos de controle, análise qualitativa de *commits* assistidos por IA e replicação em outras linguagens.

Referências

- [1] A. M. Dakhel et al., “GitHub Copilot AI pair programmer: Asset or Liability?” *J. Syst. Softw.*, 203:111806, 2023.
- [2] A. Ziegler et al., “Productivity Assessment of Neural Code Completion.” In: *Proc. MAPS*, 2022.
- [3] N. Nguyen e S. Nadi, “An empirical evaluation of GitHub Copilot’s code suggestions.” In: *Proc. MSR*, pp. 1–5, 2022.
- [4] P. Oman e J. Hagemester, “Metrics for assessing a software system’s maintainability.” In: *Proc. ICSM*, pp. 337–344, 1992.

RQ3 — M2: Maintainability Index




Figura 6: RQ3 — M2: Maintainability Index antes e depois.

- [5] E. Kalliamvakou et al., “The promises and perils of mining GitHub.” In: *Proc. MSR*, pp. 92–101, 2014.